

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN, ĐHQG-HCM
KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO ĐỒ ÁN CUỐI KỲ

IMAGE INPAINTING WITH DIFFUSION MODELS

CSC16004 – Thị giác máy tính

Nhóm sinh viên thực hiện:

Trần Đức Quân	23120075
Khổng Đức Tiến	23120173
Nguyễn Phúc Định Quyền	23120349

Giảng viên hướng dẫn:

TS. Trần Thái Sơn
ThS. Phạm Minh Hoàng

Lớp: 23CNTN

TP. Hồ Chí Minh, tháng 6 năm 2026

Mục lục

1	Thông tin về nhóm	3
2	Tổng quan về đề tài	4
2.1	Động lực nghiên cứu	4
2.2	Phát biểu bài toán	5
2.3	Ý nghĩa khoa học	6
2.4	Ý nghĩa thực tiễn	6
2.5	Thách thức bài toán	7
2.6	Phạm vi bài toán	8
3	Các nghiên cứu liên quan	10
3.1	Latent Diffusion Models	10
3.2	Fourier-based Inpainting	10
3.3	BrushNet	10
3.4	Region-Aware Diffusion	11
3.5	Inpaint Anything	11
3.6	Paint by Inpaint	11
4	Hướng tiếp cận dự kiến	12
4.1	Vấn đề của các hướng nghiên cứu trước đây	12
4.2	Hướng tiếp cận của đề tài	12
5	Thực nghiệm	14
5.1	Tập dữ liệu	14
5.2	Độ đo đánh giá	15
5.3	Các thí nghiệm	18
6	Kết luận	19
	Tài liệu tham khảo	20

1 Thông tin về nhóm

STT	Họ và tên	MSSV	Email
1	Trần Đức Quân	23120075	23120075@student.hcmus.edu.vn
2	Khổng Đức Tiến	23120173	23120173@student.hcmus.edu.vn
3	Nguyễn Phúc Định Quyền	23120349	23120349@student.hcmus.edu.vn

2 Tổng quan về đề tài

2.1 Động lực nghiên cứu

Trong bối cảnh kỷ nguyên số hóa hiện đại, hình ảnh trực quan đóng vai trò nền tảng trong việc lưu trữ thông tin, truyền thông đại chúng và bảo tồn di sản văn hóa. Tuy nhiên, trong thực tế triển khai và lưu trữ, các bộ dữ liệu hình ảnh thường xuyên phải đối mặt với tình trạng suy giảm chất lượng hoặc mất mát thông tin cục bộ. Sự xuống cấp vật lý của các bức ảnh lịch sử do tác động của thời tiết, môi trường và thời gian, sự xuất hiện của các đối tượng không mong muốn lọt vào khung hình trong nhiếp ảnh thương mại, hoặc các lỗi phát sinh trong quá trình nén và truyền tải dữ liệu số là những vấn đề phổ biến và cấp thiết. Các phương pháp chỉnh sửa và phục chế ảnh truyền thống đòi hỏi sự can thiệp thủ công từ các chuyên gia đồ họa và thiết kế. Quá trình này không chỉ tiêu tốn một lượng lớn thời gian và công sức mà còn tiềm ẩn nguy cơ sai lệch do sự chủ quan của con người, đặc biệt là khi phải xử lý các tác phẩm nghệ thuật phức tạp hoặc giải quyết bài toán trên quy mô các tập dữ liệu khổng lồ.

Việc áp dụng các kỹ thuật phục chế kỹ thuật số cho phép tái tạo hình ảnh một cách hoàn toàn không xâm lấn, mở ra cơ hội bảo tồn các di sản văn hóa vật thể mà không gây rủi ro phá hủy kết cấu gốc. Từ nhu cầu thực tiễn khổng lồ này, kỹ thuật khôi phục ảnh (**Image Inpainting**) đã vươn lên trở thành một trong những lĩnh vực nghiên cứu trọng điểm nhất của thị giác máy tính, với mục tiêu cốt lõi là lấp đầy các vùng bị thiếu hoặc bị che khuất trong một bức ảnh sao cho kết quả cuối cùng đạt được sự hài hòa tối đa về mặt cấu trúc và tự nhiên về mặt thị giác.

Động lực chính để triển khai các nghiên cứu sâu rộng hơn về chủ đề này trong giai đoạn hiện tại xuất phát từ những bước nhảy vọt mang tính cách mạng của Generative AI, đặc biệt là sự trỗi dậy mạnh mẽ của các mô hình diffusion. Các phương pháp sinh ảnh thế hệ trước, tiêu biểu là Generative Adversarial Networks (GANs) [1], đã đạt được những thành tựu nhất định trong việc tạo ra kết cấu hình ảnh sắc nét. Mặc dù vậy, hệ sinh thái GAN nhanh chóng bộc lộ các điểm nghẽn nghiêm trọng về sự bất ổn định trong quá trình huấn luyện, hiện tượng sụp đổ mode (mode collapse), và sự thiếu hụt khả năng khái quát hóa trên các tập dữ liệu có phân phối phức tạp.

Mô hình diffusion, với khả năng mô hình hóa các phân phối dữ liệu đa chiều thông qua quá trình khử nhiễu lặp đi lặp lại có cơ sở nhiệt động lực học, đã thiết lập một tiêu chuẩn công nghệ mới về độ chân thực và tính đa dạng của hình ảnh được tạo ra. Việc khai thác và tận dụng khối lượng kiến thức tiên nghiệm khổng lồ được mã hóa bên trong các mô hình diffusion tiền huấn luyện như Stable Diffusion [2] mang lại tiềm năng to lớn để giải quyết triệt để bài toán khôi phục ảnh. Cách tiếp cận này đáp ứng nhu cầu cấp thiết từ việc tự động hóa trong ngành công nghiệp nhiếp ảnh, nâng cao trải nghiệm thực tế ảo, xử lý hậu kỳ trong thương mại điện tử, cho đến các dự án bảo tồn di sản văn hóa mang tầm cỡ quốc gia.

2.2 Phát biểu bài toán

Bài toán khôi phục ảnh (Image Inpainting) có thể được định nghĩa như một bài toán tối ưu hóa đa mục tiêu và sinh dữ liệu có điều kiện trong không gian đa chiều. Mục tiêu của hệ thống là suy diễn và tạo ra các điểm ảnh mới để thay thế cho các điểm ảnh bị mất, dựa trên ngữ cảnh của các khu vực xung quanh.

Về mặt không gian trạng thái, đầu vào của bài toán bao gồm hai ma trận thông tin chính được cung cấp đồng thời cho hệ thống. Thứ nhất là ảnh bị hỏng I_{masked} , đại diện cho một bức ảnh màu đã bị mất đi một phần dữ liệu không gian do hư hỏng vật lý hoặc do sự can thiệp cố ý che khuất của người dùng. Thứ hai là mặt nạ nhị phân M , một ma trận có cùng kích thước không gian vật lý với ảnh gốc I_{masked} . Trong cấu trúc của ma trận mặt nạ này, các giá trị pixel bằng 1 (hoặc 255 tùy chuẩn hóa) đại diện cho vùng bị che khuất, và các giá trị bằng 0 đại diện cho các vùng pixel hợp lệ chứa thông tin gốc. Bài toán yêu cầu hệ thống phải có khả năng xử lý linh hoạt nhiều dạng cấu trúc mặt nạ khác nhau, từ các dạng hình học cơ bản như hình chữ nhật che khuất trung tâm, các vùng khuyết ngẫu nhiên rải rác, cho đến các mặt nạ nét vẽ tự do không theo quy luật do người dùng trực tiếp cung cấp thông qua giao diện tương tác. Sự đa dạng của mặt nạ đặt ra thách thức lớn đối với khả năng khái quát hóa của thuật toán, buộc mạng nơ-ron phải học cách suy luận từ bất kỳ hướng nào thay vì chỉ học các mẫu nội suy tĩnh.

Đầu ra của bài toán là một bức ảnh hoàn chỉnh I_{out} phải thỏa mãn nghiêm ngặt hai điều kiện tiên quyết. Điều kiện thứ nhất là tính nhất quán của dữ liệu hiện có. Các vùng không bị che khuất trong ảnh đầu ra I_{out} phải được bảo toàn nguyên vẹn hoặc gần như không đổi so với phần dữ liệu hợp lệ của ảnh gốc. Tính chất này được biểu diễn qua phương trình toán học: $I_{out} \odot (1 - M) = I_{masked} \odot (1 - M)$, với ký hiệu $\odot$ đại diện cho phép nhân ma trận Hadamard tại từng điểm ảnh. Điều kiện thứ hai là tính hợp lý về mặt ngữ nghĩa và thị giác. Phần dữ liệu được hệ thống sinh mới $I_{out} \odot M$ phải kết nối liền mạch một cách hoàn hảo với bối cảnh xung quanh về mặt ánh sáng, màu sắc, và kết cấu cục bộ, đồng thời phải tuân thủ nghiêm ngặt tính logic và cấu trúc tổng thể của toàn bộ bức ảnh.

Phân tích ở cấp độ lý thuyết thông tin, Image Inpainting về bản chất là một bài toán thiếu ràng buộc ở mức độ cao. Tồn tại vô số cấu hình điểm ảnh khả thi để điền vào một vùng không gian trống mà vẫn có thể mang lại ý nghĩa thị giác hợp lý cho người quan sát. Ví dụ, việc che đi một phần khu rừng có thể được hệ thống lấp đầy bằng một cái cây mới, một tảng đá, hoặc một con suối, và tất cả đều hợp lý. Do đó, mục tiêu của các mô hình học sâu sinh hình ảnh không phải là tìm ra một đáp án đúng duy nhất, mà là tìm ra một mẫu thuộc về phân phối có xác suất cận biên cao nhất của đa tập dữ liệu hình ảnh tự nhiên, được định hướng bởi phần ngữ cảnh còn lại và các điều kiện bổ sung.

2.3 Ý nghĩa khoa học

Việc nghiên cứu và giải quyết bài toán Image Inpainting mang lại những đóng góp nền tảng cho sự phát triển của khoa học máy tính và lý thuyết thị giác máy tính. Về bản chất, bài toán này thúc đẩy việc thấu hiểu cách thức các kiến trúc mạng nơ-ron sâu mô hình hóa các biểu diễn hình ảnh đa cấp độ, từ mức độ vi mô là các đặc trưng kết cấu bề mặt đến mức độ vĩ mô là các cấu trúc ngữ nghĩa và tính đối xứng hình học.

Việc ứng dụng các mô hình diffusion vào inpainting cung cấp một lăng kính rõ nét để các nhà khoa học nghiên cứu về cơ chế khử nhiễu nhiệt động lực học và cách thức thông tin không gian được truyền tải thông qua quá trình lặp. Khác với cơ chế mã hóa và giải mã diễn ra trong một bước duy nhất của GAN, việc bóc tách quá trình sinh hình ảnh thành hàng chục hoặc hàng trăm bước thời gian vi phân trong mô hình diffusion cho phép giới nghiên cứu can thiệp sâu vào cấu trúc không gian tiềm ẩn. Việc này mở ra khả năng khám phá các chiến lược điều khiển quá trình sinh hình ảnh một cách tinh vi dựa trên các điều kiện đa phương thức, chẳng hạn như kết hợp sự hướng dẫn của văn bản, bản đồ phân vùng ngữ nghĩa, và các phác thảo cấu trúc để ép buộc mô hình tuân thủ theo các quy luật vật lý và logic. Hơn nữa, việc nghiên cứu các hàm mất mát và các thước đo sự tương đồng nhận thức trong inpainting giúp thu hẹp khoảng cách giữa các phép tính toán học truyền thống và hệ thống thị giác sinh học của con người.

2.4 Ý nghĩa thực tiễn

Tính ứng dụng của bài toán khôi phục ảnh có tác động chuyển đổi sâu sắc đến nhiều ngành công nghiệp và dịch vụ trong thực tế. Trong lĩnh vực bảo tồn di sản và nghệ thuật, inpainting cung cấp các công cụ luận suy mạnh mẽ để phục chế kỹ thuật số các bức tranh cổ, bích họa thời kỳ Phục hưng, và các tài liệu lịch sử bị bào mòn bởi thời gian. Các chuyên gia bảo tồn có thể sử dụng hệ thống như một cơ chế gợi ý để tái tạo các chi tiết hoa văn bị mất trên cổ vật mà không cần thực hiện các thao tác vật lý, giúp giảm thiểu tuyệt đối nguy cơ phá hủy kết cấu gốc và đưa các tác phẩm này trở lại không gian trưng bày kỹ thuật số.

Trong lĩnh vực chỉnh sửa ảnh thương mại và sản xuất truyền thông điện ảnh, inpainting giải quyết một trong những bài toán tốn kém nhất ở khâu hậu kỳ: loại bỏ các đối tượng không mong muốn như người đi đường lọt vào khung hình, hệ thống dây điện phức tạp, micro thu âm, hoặc các biểu trưng bản quyền ra khỏi hình ảnh và video một cách hoàn toàn tự nhiên. Việc tích hợp các hệ thống inpainting dựa trên học sâu vào các phần mềm thương mại chuyên nghiệp hỗ trợ tự động hóa luồng công việc, giúp các nhà thiết kế và biên tập viên video tiết kiệm hàng nghìn giờ lao động thủ công mỗi năm.

Đối với ngành thương mại điện tử, các doanh nghiệp tận dụng công nghệ này để tối ưu hóa hình ảnh sản phẩm, loại bỏ các bối cảnh lộn xộn hoặc các đặc điểm nhận dạng không mong muốn, từ đó tái sử dụng hình ảnh trong các chiến dịch tiếp thị đa dạng mà không cần tổ chức lại các buổi

chụp hình tốn kém. Hơn thế nữa, trong kỷ nguyên của trí tuệ nhân tạo, kỹ thuật inpainting còn đóng vai trò như một phương pháp tăng cường dữ liệu thể hệ mới, giúp tổng hợp và sinh ra các biến thể vô hạn của hình ảnh để huấn luyện các hệ thống thị giác máy tính.

2.5 Thách thức bài toán

Mặc dù có những bước tiến vượt bậc nhờ học sâu, bài toán inpainting hiện đại vẫn đang phải đối mặt với những rào cản kỹ thuật và lý thuyết hết sức phức tạp. Quá trình xử lý không chỉ đơn thuần là sao chép điểm ảnh mà là việc tái tạo lại thực tại dựa trên thông tin bị thiếu hụt.

Thách thức đầu tiên và cốt lõi nhất là bài toán duy trì sự cân bằng giữa tính nhất quán toàn cục và cục bộ. Một bức ảnh tự nhiên bao hàm sự pha trộn phức tạp giữa cấu trúc tổng quát có tính quy luật của không gian và các chi tiết kết cấu siêu nhỏ mang tính hỗn loạn. Các phương pháp dựa trên mạng nơ-ron tích chập (CNN) truyền thống gặp giới hạn nội tại về trường cảm thụ. CNN cục bộ chỉ có khả năng quan sát một vùng không gian hẹp xung quanh khu vực đang được xử lý. Hệ quả là, khi đối mặt với các vùng khuyết có diện tích lớn, thuật toán không thể nắm bắt được bức tranh tổng thể, dẫn đến hiện tượng các vùng được lấp đầy bị mờ nhòe, thiếu hụt chi tiết tần số cao, hoặc tạo ra sự sai lệch rõ rệt về màu sắc và ánh sáng so với vùng ảnh hợp lệ ở xa.

Thách thức thứ hai nằm ở việc khôi phục cấu trúc trong các vùng khuyết đặc biệt lớn hoặc có chứa cấu trúc ngữ nghĩa phức tạp. Khi diện tích mặt nạ quá lớn so với tổng diện tích ảnh, hoặc khi mặt nạ vô tình che khuất toàn bộ một đối tượng có tính chất chu kỳ hay đối xứng sinh học nghiêm ngặt, việc nội suy thông tin trở thành một nhiệm vụ gần như bất khả thi nếu mô hình chỉ dựa vào sự liên kết điểm ảnh. Nếu hệ thống không được trang bị khả năng hiểu biết ngữ nghĩa bậc cao, nó có thể điền vào khuôn mặt một kết cấu của thảm cỏ chỉ vì phần nền xung quanh là bãi cỏ, gây ra những thảm họa về mặt thị giác và phá vỡ hoàn toàn tính logic của hình ảnh.

Thách thức thứ ba liên quan trực tiếp đến các mô hình thể hệ mới, cụ thể là nút thắt về mặt tính toán và thời gian suy luận của các mô hình diffusion. Mặc dù sở hữu năng lực sinh ảnh vượt trội, quá trình đảo ngược chuỗi Markov trong mô hình diffusion thường yêu cầu hệ thống phải thực hiện hàng chục đến hàng trăm vòng lặp suy luận qua toàn bộ mạng U-Net. Quá trình lấy mẫu chậm chạp và tiêu tốn cực kỳ nhiều tài nguyên GPU này cản trở nghiêm trọng khả năng triển khai hệ thống vào các ứng dụng đòi hỏi thời gian thực hoặc các hệ thống tương tác nhanh của người dùng cuối. Bên cạnh đó, các nghiên cứu thực nghiệm chỉ ra rằng ở những bước lấy mẫu đầu tiên, khi mức độ nhiễu loạn vẫn còn rất lớn, mô hình khuếch tán thường sử dụng rất ít thông tin điều kiện từ phần ảnh gốc. Điều này khiến quỹ đạo sinh ảnh dễ bị lệch khỏi đa tạp dữ liệu mục tiêu, đòi hỏi phải thiết kế các cơ chế đồng bộ hóa phức tạp để đưa quá trình tạo ảnh đi đúng hướng.

Cuối cùng, lĩnh vực này vấp phải sự bất đồng nghiêm trọng về độ đo đánh giá. Tồn tại một khoảng trống lớn giữa các thước đo toán học truyền thống và hệ thống nhận thức thị giác của con người. Các độ đo phổ biến như PSNR (Peak Signal-to-Noise Ratio) được xây dựng dựa trên trung bình

biên phương sai số (MSE). Sự tối ưu hóa khắt khe theo MSE có xu hướng phạt nặng sự sai lệch không gian của các chi tiết sắc nét, dẫn đến việc các mô hình học máy chọn giải pháp an toàn là làm mờ toàn bộ vùng ảnh để đạt điểm số toán học cao. Một bức ảnh được inpainting tạo ra cấu trúc kết cấu sắc nét, phong phú và vô cùng tự nhiên trong mắt con người thường bị PSNR đánh giá rất thấp chỉ vì kết cấu đó không hoàn toàn khớp từng pixel với ảnh gốc ban đầu. Điều này gây khó khăn trong việc đánh giá khách quan và định hướng tối ưu hóa cho các thể hệ thuật toán mới.

2.6 Phạm vi bài toán

Để đảm bảo tính khả thi trong quá trình nghiên cứu và mang lại chiều sâu phân tích tối đa, phạm vi của hệ thống khôi phục ảnh được giới hạn trong các ranh giới cụ thể về phương pháp luận và dữ liệu thực nghiệm.

Về giới hạn phương pháp luận, hệ thống loại bỏ các thuật toán nội suy điểm ảnh truyền thống để tập trung vào việc triển khai một mô hình học sâu hiện đại. Trọng tâm cốt lõi được đặt vào các mô hình diffusion tiên tiến đang dẫn dắt xu hướng công nghệ, trong đó đề tài lựa chọn *Stable Diffusion Inpainting* [2] làm phương pháp chính để giải quyết bài toán. Việc tập trung vào một mô hình cụ thể cho phép khai thác sâu cơ chế hoạt động, khả năng sinh ảnh và giới hạn của phương pháp diffusion trong bối cảnh inpainting, thay vì dàn trải trên nhiều hướng tiếp cận khác nhau.

Bên cạnh đó, đề tài không hướng tới việc phát triển hay cải tiến kiến trúc mô hình, mà tập trung vào việc xây dựng một pipeline hoàn chỉnh xoay quanh mô hình đã chọn, bao gồm xử lý đầu vào (mask do người dùng hoặc sinh ngẫu nhiên), thực thi inpainting và đánh giá kết quả. Các kỹ thuật nâng cao như tinh chỉnh tham số hiệu quả (PEFT), bao gồm Low-Rank Adaptation (LoRA) [3] hoặc ControlNet [4], được xem xét như một hướng mở rộng tùy chọn trong trường hợp cần thích nghi mô hình với các tác vụ đặc thù như phục chế nghệ thuật hoặc sửa chữa ảnh cũ, nhưng không phải là thành phần bắt buộc trong phạm vi chính của đề tài.

Về giới hạn dữ liệu đánh giá, hệ thống thực nghiệm được khu biệt hóa thông qua hai tập dữ liệu chuẩn mực mang tính chất đối lập nhau để kiểm tra giới hạn của thuật toán trong các môi trường nhiễu loạn khác nhau:

- **Tập dữ liệu Places2 [5]:** Đây là một tập dữ liệu quy mô khổng lồ được xây dựng bởi MIT, chứa hơn 10 triệu hình ảnh thuộc hơn 400 danh mục cảnh quan thiên nhiên, kiến trúc đô thị và không gian nội thất. Việc sử dụng Places2 đặt ra một phép thử khắc nghiệt đối với mô hình trong việc duy trì ngữ cảnh toàn cục, nhận dạng các cấu trúc phức tạp, và mô hình hóa sự hỗn loạn đa dạng của bối cảnh thực tế.
- **Tập dữ liệu CelebA-HQ [6]:** Bao gồm hơn 200.000 hình ảnh khuôn mặt người có độ phân giải siêu cao được tinh lọc từ tập CelebA gốc. Khuôn mặt con người là cấu trúc mà hệ thống thị giác sinh học nhạy cảm nhất. Việc inpainting trên tập CelebA-HQ đòi hỏi mô hình phải duy trì độ chính xác tuyệt đối về tính đối xứng hình học, cấu trúc các bộ phận, và tính chất

nhất quán của kết cấu sinh học. Do đó, đây được coi là thước đo tối thượng để đánh giá khả năng duy trì tính toàn vẹn cấu trúc và tránh các hiện tượng biến dạng kỳ dị của mô hình.

Phạm vi cấu trúc mặt nạ được hệ thống hỗ trợ trải rộng từ các thiết lập mặt nạ trung tâm tiêu chuẩn, các khối nhiễu phân bố ngẫu nhiên trong không gian ảnh, cho đến các mặt nạ nét vẽ hình khối bất quy tắc do người dùng tự định nghĩa, đảm bảo phản ánh đúng điều kiện vận hành thực tế của các phần mềm chỉnh sửa ảnh chuyên dụng.

3 Các nghiên cứu liên quan

Bài toán phục hồi ảnh nhằm mục đích lấp đầy các vùng bị thiếu hoặc bị che khuất sao cho kết quả cuối cùng đạt được sự nhất quán về cấu trúc và độ chân thực về mặt thị giác. Với sự phát triển của các mô hình học sâu, lĩnh vực này đã chuyển dịch từ các phương pháp dựa trên sự tương đồng pixel truyền thống sang các mô hình tạo sinh mạnh mẽ, tiêu biểu là các Diffusion Models.

3.1 Latent Diffusion Models

Một bước ngoặt quan trọng trong lĩnh vực sinh ảnh là sự ra đời của **Latent Diffusion Models (LDM)** do Rombach et al. [2] đề xuất. Thay vì thực hiện quá trình khử nhiễu trực tiếp trên không gian pixel vốn tốn kém tài nguyên, LDM thực hiện quá trình này trên không gian tiềm ẩn được nén bởi một bộ AutoEncoder. Với cơ chế cross-attention, Stable Diffusion Inpainting có khả năng hiểu ngữ cảnh sâu sắc và tạo ra các chi tiết sắc nét phù hợp với nội dung xung quanh. Tuy nhiên, các mô hình này thường gặp thách thức về tốc độ suy luận chậm và hiện tượng rò rỉ nhiễu, đôi khi làm thay đổi nhẹ các vùng ảnh không bị che khuất, dẫn đến có thể làm biến đổi ngữ cảnh của ảnh.

3.2 Fourier-based Inpainting

Để khắc phục nhược điểm về cấu trúc hình học của các mô hình tạo sinh, hướng tiếp cận sử dụng miền tần số được đề xuất với đại diện tiêu biểu là LaMa [7]. Bằng cách sử dụng các lớp tích chập Fourier nhanh (Fast Fourier Convolutions - FFCs), LaMa cho phép mạng Neural có trường thụ cảm bao phủ toàn bộ bức ảnh ngay từ những tầng đầu tiên. Điều này giúp mô hình xử lý cực kỳ hiệu quả các vùng mask có kích thước lớn và các cấu trúc hình học phức tạp. Ưu điểm vượt trội của LaMa là tốc độ xử lý nhanh và độ ổn định cấu trúc cao. Dù vậy, hạn chế của nó nằm ở khả năng tạo ra nội dung mới, mô hình thường chỉ lặp lại các texture có sẵn thay vì sinh ra các vật thể mới mang tính ngữ cảnh cao như các dòng Diffusion.

3.3 BrushNet

Tiếp cận bài toán dưới góc độ kiến trúc mạng, **BrushNet** [8] đề xuất mô hình inpainting với cấu trúc nhánh đôi tách biệt. Một nhánh chuyên trách việc trích xuất đặc trưng từ ảnh gốc để bảo toàn thông tin, trong khi nhánh còn lại thực hiện quá trình khuếch tán để tạo nội dung mới. Sự kết hợp này cho phép tích hợp các mô hình Stable Diffusion có sẵn mà không làm suy giảm chất lượng của các vùng ảnh nguyên vẹn, đồng thời cải thiện đáng kể sự liền mạch tại biên của vùng mask. Tuy nhiên, nhược điểm là yêu cầu tài nguyên bộ nhớ GPU lớn hơn do phải chạy song song hai mạng UNet trong quá trình suy luận.

3.4 Region-Aware Diffusion

Để giải quyết vấn đề hiệu suất và bảo toàn vùng không bị che khuất, nghiên cứu **Region Aware Diffusion (RAD)** [9] đã giới thiệu một cơ chế lịch trình nhiễu linh hoạt. Thay vì thêm nhiễu đồng nhất lên toàn bộ bức ảnh, RAD áp dụng các mức độ nhiễu khác nhau dựa trên vị trí của mask. Cách tiếp cận này giúp mô hình chỉ tập trung tài nguyên tính toán vào vùng cần phục hồi, từ đó tăng tốc độ xử lý lên nhiều lần và đảm bảo vùng ảnh gốc được giữ nguyên vẹn tuyệt đối, khắc phục nhược điểm lớn của các dòng LDM truyền thống. Nhược điểm của cách giải quyết này là thuật toán lấy mẫu đi kèm rất phức tạp, đòi hỏi kỹ thuật triển khai hệ thống khắt khe hơn so với các mô hình thông thường.

3.5 Inpaint Anything

Nhằm tối ưu hóa quy trình làm việc của người dùng, công trình **Inpaint Anything** [10] đã kết hợp mô hình phân đoạn vật thể **Segment Anything Model (SAM)** với các kỹ thuật inpainting. Thay vì yêu cầu mask vẽ tay thủ công, hệ thống cho phép người dùng xác định vật thể cần xử lý thông qua tương tác click chuột đơn giản. Việc sử dụng mask chính xác từ SAM giúp các mô hình khuếch tán hoạt động hiệu quả hơn, giảm thiểu sai sót do mask không chuẩn xác gây ra, đồng thời mở rộng khả năng ứng dụng từ xóa vật thể sang thay thế vật thể một cách thông minh.

3.6 Paint by Inpaint

Hướng nghiên cứu mới nhất năm 2025 tập trung vào việc điều khiển nội dung sinh ra một cách tinh vi. **Paint by Inpaint** [11] đã chứng minh khả năng thêm vật thể mới vào ảnh một cách tự nhiên bằng cách học từ quá trình ngược lại (xóa vật thể). Song song đó, các nghiên cứu về phục hồi tranh nghệ thuật chân dung [12] đã tinh chỉnh mô hình trên các tập dữ liệu như CelabA-HQ và Places2, giúp tái tạo các đặc trưng texture phức tạp như nét cọ sơn dầu hoặc các vết rách trên ảnh cổ với độ trung thực cao.

4 Hướng tiếp cận dự kiến

4.1 Vấn đề của các hướng nghiên cứu trước đây

Sau khi khảo sát các công trình liên quan trong bài toán image inpainting, có thể nhận thấy rằng mặc dù các phương pháp hiện đại đã đạt được nhiều tiến bộ đáng kể nhưng vẫn tồn tại một số hạn chế mang tính hệ thống khi áp dụng vào thực tế.

Thứ nhất, các phương pháp dựa trên diffusion, tiêu biểu như *Stable Diffusion* [2] và các biến thể inpainting của nó, thường yêu cầu chi phí tính toán cao do quá trình suy diễn bao gồm nhiều bước khử nhiễu lặp. Điều này dẫn đến thời gian xử lý chậm và yêu cầu tài nguyên phần cứng lớn, gây khó khăn trong việc triển khai thực tế hoặc xử lý thời gian thực.

Thứ hai, các mô hình diffusion dù có khả năng sinh ảnh với chất lượng cao, vẫn gặp hạn chế về tính nhất quán ngữ cảnh giữa vùng được inpaint và vùng ảnh đã biết. Cụ thể, trong các trường hợp mask lớn hoặc chứa các cấu trúc phức tạp (như khuôn mặt hoặc vật thể có hình dạng rõ ràng), mô hình có thể sinh ra nội dung hợp lý về mặt thị giác nhưng không hoàn toàn khớp với ngữ cảnh ban đầu của ảnh. Điều này xuất phát từ bản chất sinh xác suất của diffusion, trong đó mô hình học phân phối dữ liệu tổng quát thay vì tái tạo chính xác nội dung bị thiếu.

Thứ ba, các phương pháp không sử dụng diffusion, tiêu biểu như *LaMa* [7], mặc dù có ưu điểm về tốc độ và khả năng xử lý ảnh độ phân giải cao, lại bị hạn chế về khả năng sinh nội dung mang tính ngữ nghĩa cao. Do học ánh xạ trực tiếp từ ảnh bị che sang ảnh hoàn chỉnh, các mô hình này thường hoạt động tốt trong việc khôi phục texture hoặc các vùng có cấu trúc lặp lại, nhưng gặp khó khăn khi cần “tưởng tượng” các chi tiết mới chưa từng xuất hiện trong ảnh gốc.

Thứ tư, các phương pháp hiện tại nhìn chung tồn tại sự đánh đổi giữa các yếu tố quan trọng như chất lượng hình ảnh, tốc độ xử lý và khả năng kiểm soát nội dung. Các mô hình diffusion đạt chất lượng cao nhưng chậm và khó kiểm soát, trong khi các mô hình CNN-based nhanh hơn nhưng hạn chế về khả năng sinh ảnh phức tạp. Điều này cho thấy chưa có một giải pháp nào có thể đồng thời tối ưu tất cả các tiêu chí trong bài toán inpainting.

4.2 Hướng tiếp cận của đề tài

Dựa trên các phân tích trên, đề tài này lựa chọn hướng tiếp cận dựa trên mô hình diffusion để giải quyết bài toán image inpainting, cụ thể sử dụng *Stable Diffusion Inpainting* như mô hình chính.

Hệ thống được xây dựng nhằm phục vụ hai kịch bản chính. Thứ nhất, người dùng có thể cung cấp ảnh đầu vào và trực tiếp vẽ mask lên vùng cần chỉnh sửa, từ đó mô hình sẽ thực hiện inpainting để tạo ra ảnh hoàn chỉnh. Thứ hai, trong quá trình đánh giá, các mask ngẫu nhiên sẽ được sinh ra trên các ảnh trong tập dữ liệu nhằm mô phỏng các trường hợp mất dữ liệu, cho phép so sánh kết quả với ảnh gốc.

Để đánh giá hiệu quả của phương pháp, đề tài sử dụng các chỉ số định lượng bao gồm PSNR và SSIM nhằm đo lường độ tương đồng giữa ảnh tái tạo và ảnh gốc, đồng thời cân nhắc sử dụng thêm các perceptual metrics như LPIPS để đánh giá chất lượng thị giác của ảnh sinh ra. Cách đánh giá này giúp phản ánh cả độ chính xác về mặt pixel lẫn tính tự nhiên của kết quả.

Ngoài ra, hệ thống sẽ được thử nghiệm trên các tập dữ liệu phổ biến như Places2 và CelebA-HQ nhằm đánh giá khả năng hoạt động của mô hình trong các bối cảnh khác nhau, từ ảnh cảnh đến ảnh khuôn mặt.

Tóm lại, hướng tiếp cận của đề tài tập trung vào việc áp dụng một mô hình diffusion pretrained cho bài toán inpainting, kết hợp với việc xây dựng pipeline xử lý và đánh giá phù hợp, qua đó làm rõ hiệu quả của phương pháp diffusion trong bài toán này.

5 Thực nghiệm

5.1 Tập dữ liệu

Trong phần thực nghiệm, đồ án sử dụng tập dữ liệu **CelebA-HQ** làm tập dữ liệu chính để đánh giá các phương pháp Image Inpainting. CelebA-HQ là phiên bản chất lượng cao của tập dữ liệu CelebA, bao gồm các ảnh khuôn mặt người với độ phân giải cao, chất lượng ảnh tốt, đa dạng về giới tính, độ tuổi, kiểu tóc, biểu cảm, hướng mặt, điều kiện chiếu sáng và nền ảnh. Đây là tập dữ liệu phổ biến trong các bài toán sinh ảnh khuôn mặt, chỉnh sửa ảnh, phục hồi ảnh và Image Inpainting.

Việc lựa chọn CelebA-HQ phù hợp với mục tiêu của đồ án vì khuôn mặt có cấu trúc ngữ nghĩa rõ ràng. Khi một vùng trên khuôn mặt bị che, mô hình không chỉ cần lấp đầy màu sắc hoặc texture cục bộ, mà còn phải sinh ra nội dung hợp lý về mặt hình học và ngữ nghĩa, ví dụ như mắt, mũi, miệng, tóc hoặc da mặt. Do đó, tập dữ liệu này giúp đánh giá tốt khả năng khôi phục nội dung của các phương pháp Inpainting.

Mỗi ảnh gốc được đọc dưới dạng ảnh RGB, sau đó được tiền xử lý trước khi đưa vào thực nghiệm. Quy trình tiền xử lý bao gồm các bước:

1. Đọc ảnh gốc từ tập dữ liệu.
2. Chuyển ảnh sang định dạng RGB.
3. Center-crop ảnh thành ảnh vuông.
4. Resize ảnh về kích thước 256×256 .
5. Sinh các mask tương ứng cho ảnh.
6. Tạo ảnh masked bằng cách tô đen vùng bị che.
7. Lưu ảnh, mask và thông tin mẫu vào tệp tin `manifest.csv`.

Mỗi mẫu trong tập thực nghiệm gồm các thành phần:

- `image_path`: đường dẫn đến ảnh gốc đã tiền xử lý
- `mask_path`: đường dẫn đến mask nhị phân
- `masked_preview_path`: đường dẫn đến ảnh bị che
- `mask_type`: loại mask được sử dụng
- `sample_id`: mã định danh mẫu
- `image_size`: kích thước ảnh
- `mask_area_ratio`: tỷ lệ diện tích vùng bị che

- **seed**: seed dùng để sinh mask

Trong đó, **mask** là ảnh grayscale nhị phân cùng kích thước với ảnh đầu vào. Quy ước giá trị mask như sau:

- Pixel có giá trị 255: vùng cần được inpaint.
- Pixel có giá trị 0: vùng được giữ nguyên.

Ba loại mask được sử dụng trong thực nghiệm bao gồm:

- **Center mask**: Center mask che một vùng hình vuông ở trung tâm ảnh. Loại mask này mô phỏng trường hợp vùng trung tâm khuôn mặt bị mất thông tin, ví dụ vùng mũi, miệng hoặc một phần mắt. Đây là loại mask khó vì vùng trung tâm thường chứa nhiều chi tiết quan trọng của khuôn mặt. Với center mask, tỷ lệ diện tích mask chiếm khoảng 25% diện tích của ảnh.
- **Rectangle mask**: Rectangle mask che một vùng hình chữ nhật ngẫu nhiên trên ảnh. Loại mask này mô phỏng các vùng mất thông tin có hình dạng đơn giản, ví dụ ảnh bị che bởi một khối chữ nhật hoặc vùng ảnh bị lỗi cục bộ. Với rectangle mask, tỷ lệ diện tích mask chiếm khoảng 25% diện tích của ảnh.
- **Free-form mask**: Free-form mask được sinh bằng các nét vẽ ngẫu nhiên. Đây là loại mask gần với các tình huống thực tế hơn, ví dụ ảnh bị trầy xước, bị vật thể che khuất không đều hoặc người dùng xóa một vùng. Với free-form mask, số nét vẽ là 5, số đỉnh tối đa mỗi nét là 8, mỗi nét rộng tối đa 24 pixel và hình dạng tự do, không đều.

Sau khi sinh mask, ảnh masked được tạo ra bằng cách thay các pixel trong vùng mask bằng màu đen. Ảnh này chỉ dùng cho trực quan hóa và kiểm tra dữ liệu, không phải ảnh gốc dùng để tính metric. Các mô hình Inpainting nhận đầu vào là ảnh gốc đã tiền xử lý và mask nhị phân.

Như vậy, với tập dữ liệu **CelebA-HQ** bao gồm 30.000 ảnh mẫu. Ta thực hiện chia thành 2 phần, phần 1 bao gồm 29.000 ảnh để làm tập **train**, và phần 2 bao gồm 1.000 ảnh để làm tập **test**. Với mỗi ảnh trong từng tập **train** và **test**, ta thực hiện sinh ra 3 loại mask tương ứng để đưa vào mô hình huấn luyện, và thực hiện đánh giá sau khi huấn luyện xong.

5.2 Độ đo đánh giá

Để đánh giá toàn diện năng lực của các phương pháp trên cả ba khía cạnh: độ tương đồng pixel, chất lượng cảm nhận thị giác của con người và hiệu suất tính toán, đồ án sử dụng hệ thống 5 chỉ số đo lường sau:

5.2.1 PSNR (Peak Signal-to-Noise Ratio)

Chỉ số PSNR đo lường tỷ số giữa tín hiệu cực đại và nhiễu nền, đại diện cho độ tương đồng ở cấp độ pixel giữa ảnh phục hồi ($\hat{I}$) và ảnh gốc (I). Chỉ số PSNR càng cao chứng tỏ sai lệch về mặt giá trị pixel càng thấp.

Công thức tính chỉ số PSNR như sau:

$$MSE = \frac{1}{H \times W \times C} \sum_{i=1}^H \sum_{j=1}^W \sum_{c=1}^C \left(I(i, j, c) - \hat{I}(i, j, c) \right)^2$$

$$PSNR = 10 \log_{10} \left(\frac{MAX_I^2}{MSE} \right)$$

Trong đó:

- I là ảnh gốc sau tiền xử lý.
- $\hat{I}$ là ảnh được phục hồi bởi mô hình Inpainting.
- H , W và C lần lượt là chiều cao, chiều rộng và số kênh màu của ảnh.
- i , j và c lần lượt là chỉ số theo chiều cao, chiều rộng và kênh màu.
- MSE là sai số bình phương trung bình giữa ảnh gốc và ảnh phục hồi.
- MAX_I là giá trị pixel lớn nhất có thể của ảnh. Với ảnh RGB 8-bit, $MAX_I = 255$.

5.2.2 SSIM (Structural Similarity Index)

Chỉ số SSIM đánh giá độ tương đồng về mặt cấu trúc, độ chói (luminance) và độ tương phản (contrast) giữa ảnh sinh ra và ảnh gốc. SSIM có giá trị nằm trong khoảng $[0, 1]$, giá trị càng gần 1 thể hiện cấu trúc không gian của ảnh được bảo toàn càng tốt.

Công thức tính chỉ số SSIM như sau:

$$SSIM(I, \hat{I}) = \frac{(2\mu_I\mu_{\hat{I}} + C_1)(2\sigma_{I\hat{I}} + C_2)}{(\mu_I^2 + \mu_{\hat{I}}^2 + C_1)(\sigma_I^2 + \sigma_{\hat{I}}^2 + C_2)}$$

Trong đó:

- I là ảnh gốc sau tiền xử lý.
- $\hat{I}$ là ảnh được phục hồi bởi mô hình Inpainting.
- μ và σ lần lượt là trung bình và phương sai của các ảnh.
- $\sigma_{I\hat{I}}$ là hiệp phương sai.

- C_1 và C_2 là các hằng số ổn định.

5.2.3 LPIPS (Learned Perceptual Image Patch Similarity)

Chỉ số LPIPS đo lường khoảng cách sai biệt giữa hai ảnh dựa trên các đặc trưng tầng sâu trích xuất từ các mạng Neural tiên tiến như VGG hoặc AlexNet. LPIPS phản ánh độ tương đồng về mặt cảm nhận thị giác của con người hiệu quả hơn các chỉ số truyền thống. Giá trị LPIPS càng thấp biểu thị chất lượng cảm nhận thị giác càng cao.

Công thức tính chỉ số LPIPS như sau:

$$LPIPS(I, \hat{I}) = \sum_l w_l \|\phi_l(I) - \phi_l(\hat{I})\|_2^2$$

Trong đó:

- I là ảnh gốc sau tiền xử lý.
- $\hat{I}$ là ảnh được phục hồi bởi mô hình Inpainting.
- w_l là trọng số được học trong mạng tại layer l .
- ϕ_l là đặc trưng tại layer l của mạng.

5.2.4 FID (Fréchet Inception Distance)

Chỉ số FID đo lường khoảng cách phân phối giữa tập hợp các ảnh được mô hình sinh ra và tập hợp các ảnh thực tế (Ground-truth) thông qua không gian đặc trưng của mạng Inception-V3. Chỉ số FID đánh giá độ chân thực toàn cục và tính đa dạng của dữ liệu sinh. Giá trị FID càng nhỏ chứng tỏ phân phối ảnh sinh ra càng tiệm cận ảnh thật.

Công thức tính chỉ số FID như sau:

$$FID = \|\mu_I - \mu_{\hat{I}}\|^2 + \text{Tr} \left(\Sigma_I + \Sigma_{\hat{I}} - 2(\Sigma_I \Sigma_{\hat{I}})^{1/2} \right)$$

Trong đó:

- I là ảnh gốc sau tiền xử lý.
- $\hat{I}$ là ảnh được phục hồi bởi mô hình Inpainting.
- μ_I, Σ_I là trung bình và hiệp phương sai của ảnh I , còn $\mu_{\hat{I}}, \Sigma_{\hat{I}}$ là trung bình và hiệp phương sai của ảnh $\hat{I}$.

5.2.5 Runtime

Ngoài ra, để có được góc nhìn rộng hơn về độ hiệu quả của các phương pháp, đồ án còn thực hiện đo lường dựa trên **runtime**. Chỉ số **runtime** đo lường thời gian tính toán trung bình (tính bằng giây) để hệ thống hoàn thành tác vụ inpainting cho một bức ảnh đầu vào. Đây là chỉ số quyết định tính khả thi khi triển khai mô hình vào các ứng dụng thời gian thực.

5.3 Các thí nghiệm

Trong phần thực nghiệm, nhóm tiến hành đánh giá các phương pháp Image Inpainting trên cùng một tập dữ liệu CelebA-HQ đã được chuẩn hóa. Tất cả các phương pháp đều sử dụng cùng tập ảnh, cùng loại mask nhằm đảm bảo tính công bằng trong so sánh.

Các phương pháp được đánh giá bao gồm: **OpenCV TELEA**, **Stable Diffusion Inpainting**, **Inpaint Anything**, **Paint-by-Inpaint**, **Region-Aware Diffusion (RAD)**.

5.3.1 Thí nghiệm 1: So sánh tổng quan các phương pháp

Mục tiêu. Thí nghiệm này nhằm so sánh tổng quan chất lượng Inpainting giữa các nhóm phương pháp khác nhau: phương pháp truyền thống, mô hình diffusion pretrained, mô hình chỉnh sửa ảnh theo instruction, và các phương pháp Inpainting tiên tiến như BrushNet và RAD.

Thí nghiệm khảo sát các vấn đề sau:

- Phương pháp nào khôi phục ảnh tự nhiên nhất?
- Phương pháp nào giữ cấu trúc khuôn mặt tốt nhất?
- Các phương pháp chuyên biệt cho Inpainting như BrushNet hay RAD có vượt qua Stable Diffusion baseline không?
- Sự đánh đổi giữa chất lượng ảnh và thời gian suy luận ra sao?

6 Kết luận

Tài liệu tham khảo

- [1] I. J. Goodfellow et al., *Generative Adversarial Networks*, 2014. eprint: [arXiv:1406.2661](#).
- [2] R. Rombach, A. Blattmann, D. Lorenz, P. Esser, and B. Ommer, “High-Resolution Image Synthesis with Latent Diffusion Models”, in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022, pp. 10 684–10 695.
- [3] E. J. Hu et al., *LoRA: Low-Rank Adaptation of Large Language Models*, 2021. eprint: [arXiv:2106.09685](#).
- [4] L. Zhang, A. Rao, and M. Agrawala, *Adding Conditional Control to Text-to-Image Diffusion Models*, 2023. eprint: [arXiv:2302.05543](#).
- [5] B. Zhou, A. Lapedriza, A. Khosla, A. Oliva, and A. Torralba, “Places: A 10 million Image Database for Scene Recognition”, *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2017.
- [6] Z. Liu, P. Luo, X. Wang, and X. Tang, “Deep Learning Face Attributes in the Wild”, in *Proceedings of International Conference on Computer Vision (ICCV)*, Dec. 2015.
- [7] R. Suvorov et al., “Resolution-robust Large Mask Inpainting with Fourier Convolutions”, in *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, 2022, pp. 2149–2159.
- [8] X. Shao, Y. Wang, J. Li, et al., “BrushNet: A Plug-and-Play Image Inpainting Model with Dual-branch Diffusion”, 2024. eprint: [arXiv:2403.06976](#).
- [9] J.-H. Kim, S.-H. Park, et al., “RAD: Region-Aware Diffusion Models for Image Inpainting”, in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2025.
- [10] T. Yu et al., “Inpaint Anything: Segment Anything Meets Image Inpainting”, 2023. eprint: [arXiv:2304.06790](#).
- [11] I. Wasserman, O. Avrahami, D. Lischinski, A. Shamir, and O. Fried, “Paint by Inpaint: Learning to Add Image Objects by Removing”, in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2025.
- [12] I. W. of Conferences, “Image Inpainting of Portraits Artwork Design and Implementation”, *ITM Web of Conferences*, vol. 70, p. 03 026, 2025.